

2019年9月15日

Downscaling temperature and precipitation: a **comparison** of regression-based method and artificial neural networks.

Introduction:

研究农业生产所需要的天气尺度往往比现有模式的最高分辨率还要高。

高温持续时间的增加和低于正常水平的降水量很可能导致农作物的水汽环境改变（例如小麦和大豆），并因此对农业生产起到副作用。

Methods:

1. 研究地区: from 35° to 45° N and from 80° to 95° W, includes Indiana (IN), Illinois (IL), Ohio (OH), Kentucky (KY), Tennessee (TN), Michigan (MI), Missouri (MO), western Pennsylvania (PA), and southeastern Wisconsin (WI)




Figure 1. Map of study area showing rawinsonde stations (*) and Indianapolis, IN station (+)

2. 研究时间: 1973-1990 (共18yr)

为确保研究中选取的这18年的时间段可以代表较长时间的特征（即18年是一个较长的时间范围），每个无线电探空台站地表温度和500hPa高度的数据都和更长时间序列的数据一一比较；

——使用Kolmogorov-Smirnov(K-S) test: 用以检验两个分布是否不同。

3. 研究变量: 500hPa高度, 700hPa高度, 850hPa温度, 海平面气压 (SLP), 柱平均相对湿度 (column average relative humidity, RH)

4. 数据来源: Solar and Meteorological Surface Observation Network(SAMSON) dataset issued by the National Climatic Data Center(NCDC/NREL, 1993)

Results:

Table V. Model evaluation statistics for the regression models^a

Model	μ		σ		r	MAE	RMSE	RMSE _e	RMSE _u
	OBS	PRED	OBS	PRED					
T_{\max} GS	24.65	24.92	6.03	2.67	0.51	4.15	5.22	4.69	2.30
T_{\max} GSAU	24.65	24.88	6.03	5.25	0.85	2.31	3.18	1.58	2.76
T_{\min} GS	13.78	13.80	6.49	3.40	0.60	4.35	5.21	4.44	2.72
T_{\min} GSAU	13.78	13.85	6.49	5.52	0.88	2.39	3.08	1.63	2.61
T_{\max} NS	8.25	7.71	6.67	2.93	0.34	6.68	8.16	7.68	2.75
T_{\max} NSAU	8.25	7.46	8.67	6.64	0.81	4.04	5.17	3.39	3.90
T_{\min} NS	-3.09	-2.93	9.38	5.08	0.55	4.87	7.84	6.59	4.25
T_{\min} NSAU	-3.09	-3.66	9.38	9.59	0.80	3.23	6.09	1.83	5.81
PREC _d GS	2.69	0.66	7.19	1.12	0.36	2.97	7.16	7.09	1.04
PREC _d NS	2.76	0.49	6.06	0.99	0.50	2.72	6.07	6.01	0.86

^a The observed values are indicated by OBS, and the model predictions by PRE. The table includes the predicted and observed means (μ) and S.D.s (σ), Pearson product-moment correlation coefficient (r), MAE, RMSE, and the systematic and unsystematic components (RMSE_e and RMSE_u). The models are as described in Table IV.

Table VI. Learning rate, momentum factor, number of hidden nodes and sample sizes for the training and testing of the ANNs

Model	Learning	Momentum	# Hidden nodes	Train	Test
T_{\max} GS (°C)	0.009	0.9	10	1896	632
T_{\max} GSAU (°C)	0.01	0.5	12	1896	632
T_{\min} GS (°C)	0.012	0.9	10	2455	671
T_{\min} GSAU (°C)	0.012	0.8	10	2455	671
PREC _d GS (mm)	0.05	0.3	18	1813	604
PREC _m GS (mm)	0.3	0.05	12	68	22
T_{\max} NS (°C)	0.007	0.9	8	1316	435
T_{\max} NSAU (°C)	0.007	0.7	9	1316	435
T_{\min} NS (°C)	0.012	0.9	7	1995	611
T_{\min} NSAU (°C)	0.012	0.9	8	1995	611
PREC _d NS (mm)	0.05	0.3	15	1230	409
PREC _m NS (mm)	0.001	0.1	15	68	22

Conclusions:

- 对于日最高温变量来说, ANNs的表现要比MLR模型表现的好, ANNs中的预报值和用于预报的值之间有更高的相关系数;
- 同样, ANNs的温度模型有更小的偏差, 因此具有更大的预报性; 并且, 神经网络往往对于平均值和标准差的预估更加准确;
- 非生长季节的日最高温模型并没有生长季节的模型表现的好; 然而, 线性回归模型比神经网络能更好的预估日最高温的平均值; 无论是线性回归模型还是神经网络模型都无法捕捉方差;
- 关于PC scores的降尺度分析表明其同时含有两个季节的日最低温信息;
- 神经网络的TminGS变量要比线性回归模型更好; 在测试集中, 神经网络的相关系数要比线性回归模型略高一些;
- 无论是线性回归还是神经网络都无法成功捕捉日降水信息, 两个模型各有各的缺点导致;
- ANNs的月平均降水要远比日平均降水好很多; 这说明ANNs可以学习到数据中普遍存在的规律, 但无法捕捉到与数据相关的规律 (这些规律偏离了月降水量的平均值)。